

Framework Avaliação de Agentes

1. Visão Geral

Este documento define o framework oficial da Polaris AI para avaliação, validação e evolução de agentes de Inteligência Artificial.

O objetivo deste framework é fornecer um método padronizado para medir a qualidade, comportamento, precisão, experiência do usuário e aderência aos objetivos de negócio dos agentes desenvolvidos pela área.

A avaliação de agentes deve ser tratada como uma disciplina contínua e obrigatória durante todo o ciclo de vida da solução.

Um agente não deve ser considerado pronto apenas porque responde perguntas.

Um agente de qualidade deve:

- Resolver o problema proposto.
- Produzir respostas confiáveis.
- Demonstrar raciocínio consistente.
- Utilizar corretamente as fontes de conhecimento.
- Gerar valor para os usuários.
- Manter comportamento previsível.

2. Objetivos da Avaliação

A avaliação possui os seguintes objetivos:

- Validar a qualidade do agente.
- Medir precisão e acurácia.
- Identificar falhas e limitações.
- Detectar alucinações.
- Avaliar aderência ao objetivo.
- Avaliar experiência do usuário.
- Avaliar comportamento do agente.
- Identificar oportunidades de melhoria.
- Apoiar evolução contínua da solução.

3. Quando Avaliar um Agente

A avaliação deve ocorrer nas seguintes situações:

Durante o Desenvolvimento

Antes da publicação.

Objetivo:

Identificar problemas precocemente.

Após Alterações no Prompt

Objetivo:

Validar se o comportamento foi impactado.

Após Atualização das Fontes de Conhecimento

Objetivo:

Garantir consistência das respostas.

Antes da Publicação

Objetivo:

Homologação da solução.

Em Produção

Objetivo:

Monitorar qualidade contínua.

4. Dimensões de Avaliação

Todo agente deve ser avaliado através das dimensões abaixo.

Funcionalidade

Avalia se o agente executa corretamente sua função.

Perguntas:

- O agente resolve o problema proposto?
- O agente atende os requisitos definidos?

Qualidade

Avalia a qualidade geral das respostas.

Perguntas:

- As respostas são completas?
- As respostas são úteis?
- As respostas são compreensíveis?

Precisão

Avalia a correção das respostas.

Perguntas:

- A resposta está correta?
- A resposta possui erros?

Consistência

Avalia estabilidade do comportamento.

Perguntas:

- O agente responde de forma consistente?
- O comportamento varia indevidamente?

Governança

Avalia aderência às regras definidas.

Perguntas:

- 0 agente respeita limitações?
- 0 agente segue regras de negócio?

Agent Experience (AX)

Avalia a experiência proporcionada ao usuário.

Perguntas:

- 0 agente gera valor?
- 0 agente auxilia na solução do problema?

5. Tipos de Testes

Teste Funcional

Objetivo:

Validar funcionalidades.

Exemplos:

- Perguntas frequentes.
- Fluxos de negócio.
- Casos de uso principais.

Teste de Precisão

Objetivo:

Validar correção das respostas.

Exemplos:

- Regras de negócio.
- Procedimentos.
- Conhecimentos documentados.

Teste de RAG

Objetivo:

Validar recuperação de conhecimento.

Exemplos:

- Perguntas baseadas em documentos.
 - Perguntas sobre FAQs.
 - Recuperação de regras específicas.
-

Teste de Comportamento

Objetivo:

Validar comportamento esperado.

Exemplos:

- Seguir persona.
 - Respeitar guardrails.
 - Aplicar instruções.
-

Teste de AX

Objetivo:

Validar experiência do usuário.

Exemplos:

- Clareza.
 - Utilidade.
 - Contextualização.
 - Valor entregue.
-

6. Relatório Padrão de Avaliação

Toda avaliação de agente deve seguir obrigatoriamente o modelo abaixo.

Relatório de Avaliação de Agente

1. Identificação do Teste

Informações gerais da execução.

Campos:

ID do Teste:

Data:

Nome do Agente:

Versão:

Responsável:

Avaliador:

2. Objetivo do Teste

Descreva o propósito da avaliação.

Exemplo:

Validar a qualidade das respostas relacionadas à avaliação de prompts.

3. Entradas (Input)

Descreva exatamente o que foi enviado ao agente.

Exemplo:

"Revise o System Prompt abaixo e identifique melhorias."

4. Saídas do Agente (Output)

Registrar exatamente a resposta produzida pelo agente.

Objetivo:

Permitir rastreabilidade da avaliação.

5. Análise Funcional

Avaliar se a funcionalidade foi executada corretamente.

Critérios:

- Atendeu ao objetivo.
- Executou a tarefa esperada.
- Seguiu os requisitos.

Classificação:

Excelente
Bom
Regular
Ruim

6. Análise de Qualidade

Avaliar qualidade geral da resposta.

Critérios:

- Clareza.
- Organização.
- Utilidade.
- Completude.

Perguntas:

A resposta foi útil?

A resposta estava bem estruturada?

Classificação:

Excelente
Bom
Regular
Ruim

7. Análise de Precisão e Acurácia

Avaliar correção das informações.

Critérios:

- Precisão técnica.
- Ausência de erros.
- Ausência de alucinações.

- Aderência às fontes.

Perguntas:

A resposta está correta?

Houve invenção de informações?

Classificação:

Excelente

Bom

Regular

Ruim

8. Análise de Raciocínio do Agente

Avaliar a lógica utilizada para chegar à resposta.

Critérios:

- Coerência.
- Sequência lógica.
- Capacidade analítica.
- Justificativas apresentadas.

Perguntas:

O raciocínio foi consistente?

As recomendações foram justificadas?

Classificação:

Excelente

Bom

Regular

Ruim

9. Problemas Identificados

Documentar problemas observados.

Exemplos:

Resposta incompleta.

Informação inconsistente.

Recuperação incorreta de conhecimento.

Falta de contexto.

10. Avaliação Geral e Conclusão

Resumo executivo da avaliação.

Modelo:

Resumo Geral:

Pontos Fortes:

Pontos de Melhoria:

Riscos Identificados:

Conclusão:

7. Escala de Avaliação

Utilize a escala abaixo.

Nota	Classificação
5	Excelente
4	Bom
3	Regular
2	Ruim
1	Crítico

8. Critérios de Aprovação

Um agente pode ser considerado apto para publicação quando:

- Não apresenta erros críticos.
 - Não apresenta alucinações relevantes.
 - Atende os objetivos propostos.
 - Possui comportamento consistente.
 - Possui precisão aceitável.
 - Apresenta experiência satisfatória.
-

9. Checklist Final de Avaliação

Antes da aprovação valide:

- ☐ Funcionalidade validada.
 - ☐ Precisão validada.
 - ☐ Qualidade validada.
 - ☐ Comportamento validado.
 - ☐ AX validado.
 - ☐ RAG validado.
 - ☐ Sem erros críticos.
 - ☐ Sem alucinações relevantes.
 - ☐ Relatório concluído.
 - ☐ Recomendações registradas.
-